

경구약제 이미지 객체 검출 프로젝트

Health Eat — 알약 인식 AI 모델 개발 보고서

항목	내용
프로젝트명	경구약제 이미지 객체 검출 (Object Detection)
평가 지표	mAP@[0.75:0.95]
최종 캐글 점수	0.97581 (Public Leaderboard)
데이터셋	AI Hub 경구약제 이미지 — train 232장 / test 842장
클래스 수	56개 (test 40개)
제출자	최혜리
제출일	2026년 5월 10일

1. 프로젝트 개요

1.1 배경 및 목표

헬스케어 스타트업 Health Eat의 AI 엔지니어로서, 사용자가 모바일 앱으로 복용 중인 알약 사진을 찍으면 해당 약에 대한 정보를 제공하는 객체 검출 모델을 개발합니다. 사진 속 최대 4개의 알약의 클래스(약 이름)와 위치(바운딩 박스)를 동시에 검출하는 것이 목표입니다.

1.2 평가 방식

Kaggle Private Competition 방식으로 진행되며, 평가 지표는 $mAP@[0.75:0.95]$ 입니다. IoU 0.75~0.95 구간에서의 평균 정밀도를 측정하므로, 바운딩 박스의 정확한 위치 추정이 매우 중요합니다. 하루 최대 10회 제출이 가능합니다.

1.3 주요 도전 과제

도전 과제	상세 내용
소규모 데이터	train 232장, 클래스당 평균 4~5장으로 과적합 위험
클래스 불균형	최대 51배 불균형 (153개 vs 3개)
환경 편향	배경 100% 연회색, 조명 100% 주백색
멀티 인스턴스	한 이미지에 최대 4개 알약 동시 검출 필요
정밀한 bbox	$mAP@0.75+$ 기준으로 높은 위치 정확도 요구

2. 탐색적 데이터 분석 (EDA)

2.1 데이터셋 기본 현황

항목	수치
train 이미지 수	232장
test 이미지 수	842장
고유 클래스 수	56개 (test 40개)
어노테이션 수	763개
이미지 해상도	976 × 1280 px (100% 동일)
이미지-JSON 매칭	232개 (100% 매칭)

2.2 촬영 환경 분석

전체 데이터의 배경색이 100% 연회색, 조명이 100% 주백색으로 환경 다양성이 전혀 없습니다. 이는 모델이 실제 서비스 환경(다양한 배경/조명)에서 성능이 저하될 수 있는 주요 위험 요소입니다. 촬영 방향은 앞면 98.4%, 뒷면 1.6%로 뒷면 데이터가 매우 부족합니다.

항목	분포	비고
배경색	연회색 100%	배경 증강 필수
조명색	주백색 100%	Color Jitter 필수
촬영 방향	앞면 98.4% / 뒷면 1.6%	뒷면 데이터 부족
촬영 각도	70도 / 75도 / 90도 균등	정상

2.3 클래스 불균형 분석

전체 56개 클래스 중 최다 클래스(일양하이트린정 2mg)는 153개, 최소 클래스는 3개로 최대 51배의 불균형이 존재합니다. 하위 20%에 해당하는 17개 클래스가 어노테이션 3개 이하로, 별도의 대응 전략이 필요합니다.

2.4 이미지당 알약 수 분포

알약 수	이미지 수	비율
2개	7장	3.0%
3개	151장	65.1%
4개	74장	31.9%

3. 데이터 전처리 및 증강 전략

3.1 전처리 전략 수립

#	문제	원인	대응 전략
1	환경 편향	배경/조명 100% 단일	Color Jitter, 노이즈/블러
2	반쪽 알약 부재	분할선 있는 약 多, 반쪽 없음	CoarseDropout
3	각인 선명도	해상도·각도 차이	Sharpening, 1024px 업스케일
4	클래스 불균형	최대 51배 차이	WeightedRandomSampler
5	뒷면 부족	앞면 98.4%	뒷면 데이터 추가 수집 권장

3.2 Albumentations 증강 파이프라인

EDA 분석 결과를 바탕으로 환경 편향 해소와 다양성 확보를 위한 증강 파이프라인을 구성했습니다. 입력 해상도를 1024px로 업스케일하여 작은 각인 문자의 디테일을 보존하고, bbox_params에 min_visibility=0.3을 설정하여 증강 후 잘린 바운딩 박스를 필터링했습니다.

단계	기법	파라미터	목적
①	LongestMaxSize + PadIfNeeded	max_size=1024	고해상도 유지
②	ColorJitter	p=0.7	조명/색상 환경 편향 해소
③	GaussNoise / MotionBlur	p=0.4	노이즈 강건성
④	CoarseDropout	p=0.4	반쪽 알약 대응
⑤	HFlip / VFlip / Rotate	p=0.5/0.3/0.5	기하학적 다양성
⑥	Sharpen	p=0.3	각인 선명화
⑦	Normalize + ToTensorV2	ImageNet 기준	정규화

4. 모델 실험 및 성능 비교

4.1 Round 1 — 아키텍처 탐색

5가지 주요 객체 검출 아키텍처를 실험하여 초기 성능을 비교했습니다. 소규모 데이터셋(232장) 특성상 앵커 기반의 단순한 구조가 유리할 것으로 가정하고 실험을 진행했습니다.

모델	특징	결과	비고
DETR	Transformer 기반	낮음	소규모 데이터 부적합
Faster R-CNN (ResNet)	2-stage detector	가장 높음	정확도 우수
RetinaNet	Focal Loss 기반	중간	불균형 대응
SSD	단일 스테이지	중간	속도 우선
YOLO	실시간 검출	높음	속도+정확도 균형

→ Faster R-CNN이 최고 성능, YOLO가 속도/정확도 균형에서 유리

4.2 Round 2 — 경량화 검토

실시간 서비스 요건을 고려하여 Faster R-CNN + MobileNet 백본으로 경량화를 시도했으나, mAP가 임계값 이하로 하락했습니다. 이에 따라 Faster R-CNN을 제외하고 YOLO 계열을 메인 방향으로 확정했습니다.

4.3 Round 3 — YOLO 계열 세부 실험

모델	경로	mAP50-95	비고
YOLOv8s	baseline_yolov8s	0.985	기준 모델
YOLOv8m	yolov8m_exp	0.990	
YOLOv11s	yolo11s_exp	0.989	
YOLOv11s (aug)	yolo11s_augmented	0.941	증강 강화
YOLOv11m	yolo11m_exp	0.948	
YOLOv11l	yolo11l_exp	0.925	과적합 징후
RT-DETR-L	rt detr_exp	0.020	소규모 데이터 부적합
YOLOv11s 1280	yolo11s_1280	0.826	해상도 증가 역효과
YOLOv8l	yolov8l_exp	0.991	신규 최고
YOLOv9m	yolov9m_exp	0.990	신규
YOLOv11s (저lr)	yolo11s_lr_exp	0.992	신규 최고

5. 앙상블 전략 및 최종 결과

5.1 앙상블 방식 비교

단일 모델 성능이 높아도 앙상블을 통해 예측의 다양성을 확보하면 최종 성능이 향상됩니다. WBF(Weighted Boxes Fusion)와 Soft-NMS 두 가지 방식을 비교 실험했습니다.

방식	설명	결과
WBF	겹치는 박스를 가중 평균으로 합침	0.97414 → 0.97581
Soft-NMS	겹치는 박스의 점수를 낮춰 억제	0.96329

→ WBF가 이 데이터셋에 더 적합함 확인

5.2 WBF 파라미터 튜닝

iou_thr, skip_box_thr, conf, weights 등 다양한 파라미터를 조합하여 최적값을 탐색했습니다. 기존 3모델(v8s+v8m+v11s) equal weights 조합이 0.97414로 안정적인 성능을 보였으나, YOLOv8l을 추가한 4모델 앙상블에서 0.97581로 최고점을 달성했습니다.

파라미터	탐색 범위	최적값
iou_thr	0.45 ~ 0.60	0.55
skip_box_thr	0.10 ~ 0.40	0.20
weights	0.6 ~ 1.4 조합	균등 [1.0, 1.0, ...]
conf	0.15 ~ 0.30	0.25 (기본값)

5.3 최종 앙상블 조합 비교

조합	모델	Kaggle 점수
기존 3모델	v8s + v8m + v11s	0.97414
4모델 + v9m	v8s + v8m + v11s + v9m	0.97374
4모델 + v11slr	v8s + v8m + v11s + v11slr	0.97300
6모델 전체	v8s + v8m + v11s + v8l + v9m + v11slr	0.97410
4모델 + v8l	v8s + v8m + v11s + v8l	0.97581 (최고)

핵심 인사이트: YOLOv8l이 기존 3모델과 구조적으로 다른 큰 모델이기 때문에 앙상블 다양성이 증가했습니다. 반면 모델 수를 무조건 늘리는 것은 노이즈 증가로 오히려 성능을 저하시킬 수 있습니다.

6. 주요 의사결정 및 근거

의사결정	선택	근거
모델 방향	YOLO 계열 확정	Faster R-CNN 대비 속도/정확도 균형 우수
입력 해상도	640px (학습)	1024px는 4시간 내 3모델 학습 불가
양상블 방식	WBF	Soft-NMS 대비 0.97581 vs 0.96329
TTA 적용	각 모델 예측 시 적용	추론 다양성 확보
v8l 추가	4번째 모델로 선택	파라미터 43M으로 기존 모델과 구조적 다양성
모델 수 제한	4개 이하	6모델보다 4모델이 더 높은 점수

7. 한계점 및 개선 방향

7.1 과적합 위험

train 232장, 클래스당 평균 4~5장의 극소규모 데이터셋에서 mAP 0.97이 나온 것은 모델이 데이터를 암기했을 가능성을 배제할 수 없습니다. K-Fold Cross Validation을 통한 검증과 Grad-CAM으로 모델이 실제로 약의 외형 특징을 학습했는지 확인하는 작업이 필요합니다.

7.2 도메인 편향 (OOD 취약성)

배경 100% 연회색, 조명 100% 주백색이라는 극단적으로 단일한 환경에서 학습된 모델은 실제 사용자 환경(다양한 배경, 자연광, 스마트폰 카메라)에서 성능이 급락할 수 있습니다. 다양한 배경/조명 환경의 추가 데이터 수집이 필수적입니다.

7.3 개선 방향

분류	개선 방향	기대 효과
데이터	다양한 배경/조명 환경 추가 수집	OOD 강건성 향상
데이터	뒷면 촬영 데이터 확보 (현재 1.6%)	뒷면 인식 가능
모델	K-Fold CV로 과적합 검증	신뢰도 확보
모델	Grad-CAM 시각화로 학습 특징 확인	과적합 진단
서비스	실제 스마트폰 촬영 이미지로 Blind Test	서비스 신뢰도 검증
경량화	Knowledge Distillation (v8l→v8s)	실시간 서비스 최적화

8. 결론

본 프로젝트에서는 232장의 소규모 경구약제 이미지 데이터셋으로 mAP@[0.75:0.95] 기준 0.97581을 달성했습니다. EDA를 통해 데이터의 환경 편향과 클래스 불균형을 사전에 파악하고 이에 맞는 증강 전략을 수립한 것이 핵심이었습니다.

모델 실험에서는 5가지 아키텍처 비교 → YOLO 계열 확정 → 세부 변형 실험의 체계적인 접근으로 최적 모델을 선정했습니다. 최종적으로 YOLOv8s + YOLOv8m + YOLOv11s + YOLOv8l의 WBF 앙상블이 가장 높은 성능을 보였으며, 단순히 모델 수를 늘리는 것보다 구조적으로 다양한 모델의 조합이 중요함을 확인했습니다.

향후 실제 서비스 적용을 위해서는 다양한 환경에서의 Blind Test와 K-Fold Cross Validation을 통한 과적합 검증이 필수적입니다.

최종 결과 요약	
최고 Kaggle 점수	0.97581 (mAP@[0.75:0.95])
최적 앙상블	YOLOv8s + YOLOv8m + YOLOv11s + YOLOv8l (WBF)
WBF 파라미터	iou_thr=0.55, skip_box_thr=0.20, weights=[1,1,1,1]
총 실험 모델 수	11개 (단일) + 다수 앙상블 조합
총 캐글 제출 횟수	20회+