

Health Eat

경구약제 이미지 객체 검출 프로젝트 보고서

항목	내용
프로젝트명	경구약제 이미지 객체 검출 (Object Detection)
평가 지표	mAP@[0.75:0.95]
프로젝트 기간	2026년 4월 29일 ~ 5월 10일
개발 환경	Google Colab Pro (T4 GPU) / Google Drive
GitHub	twentycherry-gif/medicine-object-detection-project
데이터셋	AI Hub 경구약제 이미지 — train 232장 / test 842장
클래스 수	56개 (test 기준 40개)
최고 캐글 점수	0.97581 — YOLOv8s + YOLOv8m + YOLOv11s + YOLOv8l WBF 앙상블
제출자	최혜리
제출일	2026년 5월 10일

1. 프로젝트 개요

헬스케어 스타트업 Health Eat의 AI 엔지니어로서, 사용자가 모바일 앱으로 복용 중인 알약을 촬영하면 해당 약의 정보를 제공하는 객체 검출(Object Detection) 모델을 개발했습니다. 사진 속 최대 4개의 알약에 대해 클래스(약 이름)와 위치(바운딩 박스)를 동시에 검출하는 것이 목표이며, Kaggle Private Competition 방식으로 mAP@[0.75:0.95] 지표를 통해 성능을 검증했습니다.

mAP@[0.75:0.95]는 IoU 0.75~0.95 구간에서의 평균 정밀도를 측정하므로, 단순히 객체를 검출하는 것을 넘어 바운딩 박스의 정확한 위치 추정이 매우 중요합니다. 하루 최대 10회 제출이 가능하며, 캐글 점수를 기준으로 모델 성능을 트래킹했습니다.

1.1 주요 도전 과제

도전 과제	상세 내용	대응 방향
소규모 데이터	train 232장, 클래스당 평균 4~5장 → 과적합 위험	증강 강화 + WBF 앙상블
클래스 불균형	최대 51배 불균형 (153개 vs 3개)	WeightedRandomSampler
환경 편향	배경 100% 연회색, 조명 100% 주백색	ColorJitter, 노이즈/블러
멀티 인스턴스	한 이미지에 최대 4개 알약 동시 검출 필요	앵커 기반 YOLO 채택
정밀한 bbox	mAP@0.75+ 기준으로 높은 위치 정확도 요구	imgsz=1024, TTA 적용
뒷면 데이터 부족	앞면 98.4% / 뒷면 1.6%	뒷면 추가 수집 권장

2. 탐색적 데이터 분석 (EDA)

2.1 데이터셋 기본 현황

항목	수치
train 이미지 수	232장
test 이미지 수	842장
고유 클래스 수	56개 (test 기준 40개)
어노테이션 수	763개
이미지 해상도	976 × 1280 px (100% 동일)
이미지-JSON 매칭	232개 (100% 매칭)
이미지당 알약 수	2개: 7장 (3.0%) / 3개: 151장 (65.1%) / 4개: 74장 (31.9%)

※ test 이미지가 train보다 약 4배 많음 — 대회 특성상 정상

2.2 촬영 환경 분석

전체 데이터의 배경색이 100% 연회색, 조명이 100% 주백색으로 환경 다양성이 전혀 없습니다. 이는 모델이 실제 서비스 환경(다양한 배경/조명)에서 성능이 저하될 수 있는 주요 위험 요소입니다.

항목	분포	비고
배경색	연회색 100%	배경 증강 필수
조명색	주백색 100%	Color Jitter 필수
촬영 방향	앞면 98.4% / 뒷면 1.6%	뒷면 데이터 극소수
촬영 각도	70도 / 75도 / 90도 균등	정상 — Rotate 증강으로 대응

- 각도(70·75·90도)에 따라 동일 약의 이미지 내 위치(x, y)가 크게 달라짐 → 위치 기반이 아닌 외형(색상·각인·모양) 기반 학습 필요

2.3 클래스 불균형 분석

전체 56개 클래스 중 최다 클래스(일양하이트린정 2mg)는 153개, 최소 클래스는 3개로 최대 51배의 불균형이 존재합니다. 하위 20%에 해당하는 17개 클래스가 어노테이션 3개 이하로, 별도의 대응 전략이 필수입니다.

항목	수치
전체 클래스 수	56개
최다 클래스	일양하이트린정 2mg — 153개
최소 클래스	3개 (다수 약물)
최대 불균형 비율	51배
소수 클래스 수	17개 (하위 20%, 어노테이션 3개 이하)

3. 데이터 전처리 및 증강 전략

EDA 결과를 바탕으로 환경 편향 해소, 소수 클래스 보완, 각인 선명도 유지를 목표로 Albumentations 기반 증강 파이프라인을 구성했습니다. 입력 해상도를 1024px로 업스케일하여 작은 각인 문자의 디테일을 보존하고, bbox_params에 min_visibility=0.3을 설정하여 증강 후 잘린 바운딩 박스를 필터링했습니다.

3.1 전처리 전략 수립

#	문제	원인	대응 전략
1	환경 편향	배경/조명 100% 단일	Color Jitter, 노이즈/블러
2	반쪽 알약 부재	분할선 있는 약 多, 실제 반쪽 없음	CoarseDropout
3	각인 선명도 차이	이미지마다 해상도·각도 차이	Sharpening, 1024px 업스케일
4	클래스 불균형	최대 51배 차이	WeightedRandomSampler
5	뒷면 데이터 부족	앞면 98.4%, 뒷면 1.6%	뒷면 데이터 추가 수집 권장

3.2 Albumentations 증강 파이프라인

단계	기법	파라미터	목적
----	----	------	----

①	LongestMaxSize + PadIfNeeded	max_size=1024	고해상도 유지 — 각인 디테일 보존
②	ColorJitter	p=0.7	조명/색상 환경 편향 해소
③	GaussNoise / MotionBlur / GaussianBlur	p=0.4	노이즈·블러 환경 강건성
④	CoarseDropout	p=0.4	반쪽 알약 미존재 보완
⑤	HorizontalFlip / VerticalFlip / Rotate±30°	p=0.5/0.3/0.5	기하학적 다양성 확보
⑥	Sharpen	p=0.3	각인 선명화
⑦	Normalize + ToTensorV2	ImageNet mean/std	사전학습 모델 정규화 기준 통일

클래스 불균형 대응: YOLO 포맷 변환 시 WeightedRandomSampler 개념을 반영하여 소수 클래스 이미지가 더 자주 샘플링되도록 DataLoader를 구성했습니다. bbox_params에 format='coco', min_visibility=0.3 적용으로 증강 후 잘린 박스는 자동 필터링했습니다.

4. 모델 실험 및 성능 비교

4.1 Round 1 — 아키텍처 탐색

소규모 데이터셋(232장) 특성상 앵커 기반의 단순한 구조가 유리할 것으로 가정하고 5가지 주요 객체 검출 아키텍처를 실험했습니다.

모델	특징	결과	비고
DETR	Transformer 기반	낮음	소규모 데이터 부적합
Faster R-CNN	2-stage detector	가장 높음	정확도 우수, 구현 비용 높음
RetinaNet	Focal Loss 기반	중간	클래스 불균형 대응
SSD	단일 스테이지	중간	속도 우선
YOLO	실시간 검출	높음	속도+정확도 균형

→ Faster R-CNN이 최고 성능이었으나 ultralytics 같은 자동화 파이프라인이 없어 학습 루프 직접 구현 필요 → 개발 비용 대비 성능 이점 미미. YOLO 계열이 속도/정확도/편의성 균형에서 압도적으로 유리 확인

4.2 Round 2 — 경량화 검토 및 방향 확정

실시간 모바일 서비스 요건을 고려하여 Faster R-CNN + MobileNet 백본으로 경량화를 시도했으나, mAP가 임계값 이하로 하락했습니다. 이에 따라 Faster R-CNN을 제외하고 YOLO 계열을 메인 방향으로 확정했습니다.

- RT-DETR은 Transformer 기반으로 대규모 데이터에서 강점 → 232장 소규모 데이터에서 mAP 0.020 수준으로 학습 불가 확인
- Faster R-CNN 96 epoch 학습 완료 (Best Loss: 0.0848) → mAP 직접 비교 불가, 보고서 비교군으로만 활용

4.3 Round 3 — YOLO 계열 세부 실험

YOLOv8·YOLOv9·YOLOv11 다양한 변형 모델을 실험하여 최적 모델 조합을 탐색했습니다. 모든 학습은 Google Colab Pro T4 GPU 환경에서 진행했습니다.

모델	학습 경로	mAP50-95	파라미터	최종 활용
----	-------	----------	------	-------

YOLOv8s	baseline_yolov8s	0.985	11M	최종 앙상블
YOLOv8m	yolov8m_exp	0.990	25M	최종 앙상블
YOLOv8l	yolov8l_exp	0.991	43M	최종 앙상블
YOLOv11s	yolo11s_exp	0.989	9.4M	최종 앙상블
YOLOv11s (증강 강화)	yolo11s_augmented	0.941	9.4M	점수 하락
YOLOv11m	yolo11m_exp	0.948	20M	점수 하락
YOLOv11l	yolo11l_exp	0.925	25M	단독 0.747 (과적합)
YOLOv9m	yolov9m_exp	0.990	20M	앙상블 기여 미미
YOLOv11s (저lr)	yolo11s_lr_exp	0.992	9.4M	앙상블 기여 미미
YOLOv11s (1280)	yolo11s_1280	0.826	9.4M	해상도 증가 역효과
RT-DETR-L	rtdetr_exp	0.020	33M	소규모 데이터 부적합
Faster R-CNN (ResNet50)	faster_rcnn	Loss:0.085	25M	mAP 직접 비교 불가

- 모델 크기가 크다고 좋은 게 아님 → v11l(25M)이 v11s(9.4M)보다 캐글 점수 낮음 (과적합)
- 증강 강화(augv2)가 train mAP는 높아도 캐글 점수는 낮음 → 과증강은 일반화 성능 저하 초래
- 1280 해상도 모델이 앙상블 추가 시 오히려 점수 하락 → 학습/테스트 해상도 불일치 가능성

5. 앙상블 전략 및 최적화

5.1 앙상블 방식 비교 — WBF vs Soft-NMS

단일 모델 성능이 높아도 앙상블을 통해 예측의 다양성을 확보하면 최종 성능이 향상됩니다. WBF와 Soft-NMS 두 가지 방식을 직접 비교 실험했습니다.

방식	설명	캐글 점수	채택 여부
WBF	겹치는 박스를 가중 평균으로 합침	0.97581	최종 채택
Soft-NMS	겹치는 박스의 점수를 낮춰 억제	0.96329	제외

→ WBF가 이 데이터셋에서 Soft-NMS 대비 명확히 우위 확인 → WBF 최종 채택

5.2 WBF 파라미터 튜닝

iou_thr, skip_box_thr, conf, weights 등 다양한 파라미터를 조합하여 최적값을 탐색했습니다. 총 20종 이상의 앙상블 조합 및 파라미터 실험을 진행했습니다.

파라미터	탐색 범위	최적값	근거
iou_thr	0.45 ~ 0.60	0.55	0.45~0.60 모두 0.55보다 낮음
skip_box_thr	0.10 ~ 0.40	0.20	0.30→0.20 변경 시 0.97292→0.97414 상승
weights	0.6~1.4 조합	균등 1.0	boost/heavy 조합 전부 균등보다 낮음

conf	0.15 ~ 0.30	0.25	0.15 재예측 시 변화 없음
TTA	True / False	True	추론 다양성 확보

- skip_box_thr 0.30 → 0.20: 알약처럼 작은 객체는 confidence가 낮게 예측되는 경우가 있어 버리지 않는 것이 유리
→ 점수 0.97292 → 0.97414 상승 확인

5.3 캐글 제출 점수 흐름 (전체)

날짜	제출 내용	점수	비고
4/29	YOLOv8s 단독 (첫 제출)	0.95788	팀 내 초기 순위
4/29	WBF 앙상블 All (4모델)	0.97162	앙상블 효과 확인
4/30	wbf_equal_fixed (3모델 균등)	0.97292	신기록 갱신
5/1	wbf_tuned_skip20 (skip=0.20)	0.97414	신기록 갱신
5/2~3	iou/skip 튜닝 10회 전부	최고 0.97414	한계점 확인
5/4	v11l 추가·augv2·1280 실험 (7종)	최고 0.97414	새 모델 추가 효과 없음
5/5	Soft-NMS 실험	0.96329	WBF 순위 확인
5/5	YOLOv8l 추가 4모델 WBF	0.97581	최고점 경신

5.4 최종 앙상블 설정

항목	값
모델 조합	YOLOv8s + YOLOv8m + YOLOv11s + YOLOv8l
weights	[1.0, 1.0, 1.0, 1.0] (균등 가중치)
iou_thr	0.55
skip_box_thr	0.20
TTA	True
최종 캐글 점수	0.97581

- 새 모델(v11l, augv2, 1280) 추가 시 전부 점수 하락 → 기존 3모델이 서로 상호보완적인 최적 조합이었음
- YOLOv8l은 파라미터 43M으로 기존 3모델과 구조적으로 달라 앙상블 다양성에 기여 → 최고점 경신
- 5·6모델 앙상블이 오히려 점수 하락 → 과적합 모델 추가가 앙상블 노이즈로 작용함을 확인

6. 성과 및 주요 의사결정

6.1 정량적 성과

지표	수치
최종 mAP@[0.75:0.95] (캐글)	0.97581

총 실험 모델 수	11개 (YOLO 계열 9 + RT-DETR + Faster R-CNN)
총 앙상블 조합 실험 수	20종 이상
총 캐글 제출 횟수	약 30회+
학습 기간	7일 (4/29 ~ 5/5)
하루 최대 모델 학습 수	3개 (순차 학습, 외출 중 병렬 실행)

6.2 주요 의사결정 로그

- `imgsz=1024` 설정: EDA에서 원본 해상도 976×1280을 확인하고 기본값(640) 대신 1024로 설정. 작은 알약 각인 문자 디테일 보존 → 팀 내 초기 점수 우위 확보의 핵심 요인으로 추정
- YOLO 계열 확정: RT-DETR(mAP 0.020)·Faster R-CNN(직접 구현 필요) 실험 후 배포 가능성·성능·개발 비용을 종합 판단 → YOLO 최종 선택
- 640px 학습 해상도 채택: 1024px는 Colab T4 환경에서 4시간 내 3개 모델 학습 불가 → 640px로 학습 후 TTA(`augment=True`)로 추론 시 다양성 확보
- 균등 가중치 유지: 가중치 그리드 서치(0.6~1.4, 125가지 조합) 및 `boost/heavy` 조합 실험 결과 균등 가중치가 지속적으로 최고점 → 특정 모델 편향 없이 앙상블
- WBF 채택: Soft-NMS(0.96329) 대비 WBF(0.97414) 우위 실험으로 확인 후 최종 방식 확정
- 모델 수 4개 이하 유지: 5·6모델 앙상블이 오히려 점수 하락 → 과적합 모델 추가가 앙상블 노이즈로 작용 확인
- `category_id` 버그 구조적 해결: YOLO 내부 인덱스(1~56)로 제출 시 캐글 0점 처리 → `pred CSV` 자체를 `dl_idx`로 변환해 저장하는 구조적 해결로 재발 방지

7. 한계점 및 개선 방향

7.1 과적합 위험 (핵심 한계)

train 232장, 클래스당 평균 4~5장의 극소규모 데이터셋에서 mAP 0.97이 나온 것은 모델이 데이터를 암기했을 가능성을 배제할 수 없습니다. K-Fold Cross Validation을 통한 검증과 Grad-CAM으로 모델이 실제로 약의 외형 특징을 학습했는지 확인하는 작업이 필요합니다.

7.2 도메인 편향 (OOD 취약성)

배경 100% 연회색, 조명 100% 주백색이라는 극단적으로 단일한 환경에서 학습된 모델은 실제 사용자 환경(다양한 배경, 자연광, 스마트폰 카메라)에서 성능이 급락할 수 있습니다.

7.3 개선 방향 요약

분류	개선 방향	기대 효과
데이터	다양한 배경·조명 환경 이미지 추가 수집	OOD 강건성 향상
데이터	뒷면 촬영 데이터 확보 (현재 1.6%, 5종 약물)	뒷면 알약 인식 가능
데이터	소수 클래스 17개 이미지 추가 수집 및 합성	클래스 불균형 완화

모델	K-Fold CV로 과적합 여부 검증	신뢰도 확보
모델	Grad-CAM 시각화로 학습 특징 확인	과적합 진단
모델	Knowledge Distillation (v8l → v8s)	실시간 서비스 최적화
서비스	실제 스마트폰 촬영 이미지로 Blind Test	서비스 신뢰도 검증
서비스	RT-DETR 재실험 (대규모 데이터 확보 후)	Transformer 잠재력 검증

8. 프로젝트를 통해 얻은 것

비개발자 출신으로 시작해 mAP@[0.75:0.95] 기반 객체 검출 프로젝트를 처음부터 끝까지 직접 수행했습니다. 단순히 코드를 실행하는 것을 넘어 '왜 그 결과가 나왔는지'를 분석하고 다음 실험을 설계하는 과정을 반복하면서 AI 엔지니어의 실무 사이클을 체득했습니다.

- 데이터 규모에 따른 모델 선택 기준: RT-DETR 실패(mAP 0.020)가 오히려 'Transformer는 대규모 데이터가 필요하다'는 명확한 인사이트 제공
- 해상도(imgsz)의 결정적 역할: mAP@0.75 이상 고정밀 평가에서 1024px 업스케일이 640px 대비 유의미한 성능 차이를 만든다는 것을 체감
- 앙상블은 '다양성'이 핵심: '많을수록 좋다'가 아니라 서로 다른 구조의 모델이 상호보완적으로 작용하는 것이 중요함을 실험으로 확인
- 하이퍼파라미터 감각 습득: skip_box_thr 파라미터 하나의 변경(0.30→0.20)이 실제 캐글 점수에 영향을 주는 과정을 직접 체험
- 구조적 디버깅 습관: category_id 버그 → 근본 원인 파악 → pred CSV 자체 변환으로 구조적 해결 → 같은 실수 반복 방지
- 시간 효율화 패턴: Colab 학습 중 외출·강의 수강 병행으로 7일간 11개 모델 + 20종 앙상블 실험 완료
- 딥러닝 개념의 현실 연결: 인생네컷·포토샵·틱톡 배경제거 전부 CNN/GAN 기반이라는 것을 파악 → 딥러닝이 이미 일상에 깊이 적용됨을 체감
- KFA 서비스 파이프라인 구체화: MediaPipe(랜드마크 추출) → CNN(얼굴형 분류) → 추천 모델(헤어 매칭) 구조를 이번 프로젝트를 통해 설계 방향 확정

9. 결론

본 프로젝트에서는 232장의 소규모 경구약제 이미지 데이터셋으로 mAP@[0.75:0.95] 기준 0.97581을 달성했습니다. EDA를 통해 데이터의 환경 편향과 클래스 불균형을 사전에 파악하고 이에 맞는 증강 전략을 수립한 것이 핵심이었으며, 모델 실험에서는 5가지 아키텍처 비교 → YOLO 계열 확정 → 세부 변형 실험의 체계적인 접근으로 최적 모델을 선정했습니다.

최종적으로 YOLOv8s + YOLOv8m + YOLOv11s + YOLOv8l의 WBF 앙상블이 가장 높은 성능을 보였으며, 단순히 모델 수를 늘리는 것보다 구조적으로 다양한 모델의 조합이 중요함을 확인했습니다. 향후 실제 서비스 적용을 위해서는 다양한 환경에서의 Blind Test와 K-Fold Cross Validation을 통한 과적합 검증이 필수적입니다.

항목	내용
----	----

최고 캐글 점수	0.97581 (mAP@[0.75:0.95])
최적 앙상블	YOLOv8s + YOLOv8m + YOLOv11s + YOLOv8l (WBF)
WBF 파라미터	iou_thr=0.55 / skip_box_thr=0.20 / weights=[1,1,1,1] / TTA=True
총 실험 모델 수	11개 단일 모델 + 20종 이상 앙상블 조합
총 캐글 제출 횟수	약 30회+
학습 기간	7일 (2026.04.29 ~ 05.05)

10. 부록: 프로젝트 디렉토리 구조

```
pill_detection/ (Google Drive 기준)
├── data/
│   ├── train_images/ ← 232장
│   ├── train_annotations/ ← COCO JSON (763개)
│   └── test_images/ ← 842장
├── yolo_data/
│   ├── images/train|val/
│   ├── labels/train|val/
│   └── data.yaml ← 56 classes
├── runs/ ← 11개 모델 학습 결과 (best.pt)
├── outputs/ ← 예측 CSV (pred_v8s.csv 등)
├── notebooks/
├── 01_eda_setup.ipynb
├── 02_train_yolo_ensemble.ipynb
├── 02_rtdetr_experiment.ipynb
├── 02_faster_rcnn_experiment.ipynb
├── 03_wbf_hyperparameter_tuning.ipynb
├── 04_new_models_ensemble_experiments.ipynb
└── 05_softnms_new_models_final_ensemble.ipynb
```

실험 노트북 목록

파일명	주요 내용
01_eda_setup.ipynb	환경 셋업, COCO JSON 파싱, bbox 시각화, YOLO 포맷 변환, 베이스라인 학습
02_train_yolo_ensemble.ipynb	YOLOv11m 학습, TTA 예측 CSV 생성, WBF 앙상블, category_id 버그 수정
02_rtdetr_experiment.ipynb	RT-DETR-L 50 epoch 학습 — mAP 0.020 확인 (소규모 데이터 부적합)
02_faster_rcnn_experiment.ipynb	Faster R-CNN ResNet50 FPN 직접 구현, Early Stopping, Best Loss 0.0848
03_wbf_hyperparameter_tuning.ipynb	category_id dl_idx 변환, iou_thr/skip_box_thr 튜닝 실험, day4 CSV 생성
04_new_models_ensemble_experiments.ipynb	YOLOv11l·YOLOv11s 1280·YOLOv8m 1280·augv2 학습, 앙상블 실험
05_softnms_new_models_final_ensemble.ipynb	테스트 EDA, Soft-NMS 실험, YOLOv8l·v9m·v11s_lr 학습, 최고점 0.97581 달성