

Health Eat

경구약제 이미지 객체 검출 프로젝트 보고서

항목	내용
프로젝트명	경구약제 이미지 객체 검출 (Object Detection)
평가 지표	mAP@[0.75:0.95]
기간	2026년 4월 29일 ~ 5월 10일
환경	Google Colab Pro (T4 GPU) / Google Drive
GitHub	twentycherry-gif/medicine-object-detection-project
최고 캐글 점수	0.97581 (YOLOv8s + YOLOv8m + YOLOv11s + YOLOv8l WBF 앙상블)

1. 프로젝트 개요

헬스케어 스타트업 Health Eat의 AI 엔지니어로서, 모바일 앱에서 사용자가 촬영한 알약 이미지를 인식하고 해당 약의 정보를 제공하는 객체 검출 모델을 개발했습니다. 사진 속 최대 4개의 알약에 대해 클래스(약품명)와 위치(바운딩 박스)를 검출하는 것이 목표이며, Kaggle Private Leaderboard의 mAP@[0.75:0.95] 지표로 성능을 검증했습니다.

구분	내용
train 이미지	232장
test 이미지	842장
클래스 수	56개 (test 기준 40개)
이미지 해상도	976 × 1280 px (전체 동일)
어노테이션 수	763개
클래스 불균형	최대 51배 (최소 3개 ~ 최대 153개)
제출 포맷	COCO 형식 CSV (annotation_id, image_id, category_id, bbox_x/y/w/h, score)

2. 데이터 EDA 핵심 인사이트

- 환경 편향 심각: 배경 100% 연회색, 조명 100% 주백색 → 실제 서비스 환경과 다를 가능성 높음 → ColorJitter-배경 합성 증강 필수
- 클래스 불균형: 최대 51배 불균형 (일양하이트린정 153개 vs 소수 클래스 3개) → WeightedRandomSampler + 소수 클래스 증강 권장
- 뒷면 데이터 부족: 앞면 98.4% / 뒷면 1.6% → 뒷면 학습 데이터 극소수로 뒷면 알약 오검출 위험
- 각도 다양성: 70·75·90도 균등 분포 → 위치 기반이 아닌 외형(색상·각인·모양) 기반 학습 필요, Rotate 증강 필수
- 고해상도 유지 필요: 976×1280px 원본에서 각인 문자 디테일이 중요 → 학습 시 1024px 업스케일 적용
- 멀티 인스턴스: 이미지당 3~4개 알약 동시 촬영 → 앵커 기반 멀티 객체 검출 모델 필요

3. 데이터 전처리 및 증강

EDA 결과를 바탕으로 환경 편향 해소, 소수 클래스 보완, 각인 선명도 유지를 목표로 Albumentations 기반 증강 파이프라인을 구성했습니다.

단계	기법	목적
①	LongestMaxSize(1024) + PadIfNeeded	고해상도 유지 — 각인 문자 디테일 보존
②	ColorJitter (p=0.7)	조명/색상 편향 해소
③	GaussNoise / MotionBlur / GaussianBlur (p=0.4)	노이즈 및 블러 환경 대응
④	CoarseDropout (p=0.4)	반쪽 알약 미존재 보완

⑤	HorizontalFlip / VerticalFlip / Rotate±30°	방향 다양성 확보
⑥	Sharpen (p=0.3)	각인 선명화
⑦	Normalize (ImageNet mean/std) + ToTensorV2	사전학습 모델 정규화 기준 통일

클래스 불균형 대응: YOLO 포맷 변환 시 WeightedRandomSampler 개념을 반영하여 소수 클래스 이미지가 더 자주 샘플링되도록 DataLoader를 구성했습니다.

4. 모델 개발 및 실험

4-1. 모델 아키텍처 비교

모델	특징	mAP50-95	캐글 활용
YOLOv8s	1-stage, 파라미터 11M, 빠른 추론	0.985	최종 앙상블
YOLOv8m	1-stage, 파라미터 25M, 균형형	0.990	최종 앙상블
YOLOv8l	1-stage, 파라미터 43M, 고성능	0.991	최종 앙상블
YOLOv11s	경량 최신 구조, 파라미터 9.4M	0.989	최종 앙상블
YOLOv11s (aug)	증강 강화 버전	0.941	점수 하락
YOLOv11m	파라미터 20M	0.948	점수 하락
YOLOv11l	파라미터 25M, 과적합 발생	0.925	단독 0.747
YOLOv9m	새 구조 실험	0.990	앙상블 기여 미미
RT-DETR-L	Transformer 기반	0.020	소규모 데이터 부적합
Faster R-CNN	2-stage, ResNet50 FPN	Loss: 0.085	mAP 직접 비교 불가

- RT-DETR은 Transformer 기반으로 대규모 데이터에서 강점을 가지나 232장의 소규모 데이터에서는 학습 불가 수준이었음 → 데이터 규모에 따른 모델 선택 기준 인사이트 확보
- Faster R-CNN은 ultralytics 같은 자동화 파이프라인이 없어 학습 루프 직접 구현 필요 → 개발 비용 대비 성능 이점 미미

4-2. 주요 의사결정: YOLO 선택 근거

모바일 앱 배포 관점에서 모델을 선정했습니다. RT-DETR(0.020)과 Faster R-CNN(직접 구현 필요)을 실험한 결과, 추론 속도·경량성·파이프라인 편의성·성능 모두에서 YOLO 계열이 압도적으로 유리하다는 결론을 도출했습니다.

5. 앙상블 및 최적화

5-1. WBF(Weighted Boxes Fusion) 앙상블 채택 근거

WBF는 겹치는 박스들을 가중 평균으로 합쳐서 하나의 박스를 만드는 방식이고, Soft-NMS는 겹치는 박스의 점수를 낮추는 방식입니다. 실험 결과 Soft-NMS(0.96329) < WBF(0.97414)로 WBF가 이 데이터셋에 더 적합함을

확인했습니다.

5-2. 캐글 제출 점수 흐름

날짜	제출 내용	점수	비고
4/29	YOLOv8s 단독 (첫 제출)	0.95788	팀 2위 시작
4/29	WBF 앙상블 All (4모델)	0.97162	앙상블 효과 확인
4/30	wbf_equal_fixed (3모델 균등)	0.97292	신기록 갱신
5/1	wbf_tuned_skip20 (skip=0.20)	0.97414	신기록 갱신
5/2~3	iou/skip 튜닝 10회	최고 0.97414	한계점 확인
5/4	v11l 추가·augv2·1280 실험	최고 0.97414	새 모델 추가 효과 없음
5/5	Soft-NMS 실험	0.96329	WBF 우위 확인
5/5	YOLOv8l 추가 4모델 WBF	0.97581	최고점 경신

5-3. 최종 앙상블 설정

항목	값
모델 조합	YOLOv8s + YOLOv8m + YOLOv11s + YOLOv8l
weights	[1.0, 1.0, 1.0, 1.0] (균등 가중치)
iou_thr	0.55 (0.45·0.60 실험 후 0.55 최적 확정)
skip_box_thr	0.20 (0.30→0.20으로 낮추자 점수 상승)
TTA	True
최종 캐글 점수	0.97581

- skip_box_thr 0.30 → 0.20 변경으로 0.97292 → 0.97414 상승: 알약처럼 작은 객체는 confidence가 낮게 예측되는 경우가 있어 버리지 않는 것이 유리했음
- 새 모델(v11l, augv2, 1280) 추가 시 전부 점수 하락 → 기존 3모델이 서로 상호보완적인 최적 조합이었음. YOLOv8l은 구조적으로 다른 큰 모델이라 앙상블 다양성에 기여하여 점수 상승

6. 성과 및 주요 의사결정

6-1. 정량적 성과

지표	수치
최종 mAP@[0.75:0.95] (캐글)	0.97581
총 실험 모델 수	11개 (YOLO 계열 9 + RT-DETR + Faster R-CNN)
총 캐글 제출 횟수	약 30회+

양상블 조합 실험 수	20종 이상
학습 기간	7일 (4/29~5/5)

6-2. 주요 의사결정 로그

- `imgsz=1024` 설정: EDA에서 원본 해상도 976×1280을 확인하고 기본값(640) 대신 1024로 설정. 작은 알약 각인 디테일 보존 → 팀 내 초기 점수 우위 확보의 핵심 요인으로 추정
- YOLO 최종 선택: RT-DETR(mAP 0.020)·Faster R-CNN(직접 구현 필요) 실험 후 배포 가능성·성능·개발 비용 종합 판단
- 균등 가중치 유지: 가중치 그리드 서치 및 boost 조합 실험 결과 균등 가중치가 지속적으로 최고점 → 특정 모델 편향 없이 양상블
- WBF 채택: Soft-NMS(0.96329) 대비 WBF(0.97414) 우위 확인 후 최종 방식으로 확정
- 모델 수 3~4개 유지: 5·6모델 양상블이 오히려 점수 하락 → 과적합된 모델 추가가 양상블 노이즈로 작용

7. 한계점 및 개선 방향

한계점	원인	개선 방향
train 232장 소규모	데이터 수집 제한	AI Hub 추가 데이터 수집 (금지 2종 제외)
배경·조명 단일 환경	100% 연회색 배경, 주백색 조명	다양한 배경·조명 이미지 추가 수집
뒷면 데이터 1.6%	앞면 위주 촬영	뒷면 알약 이미지 추가 수집 (5종 약물)
소수 클래스 17개	어노테이션 3개 이하	해당 클래스 이미지 추가 수집·합성
OOD 취약성	train=test 분포 유사 가능성	실제 촬영 환경 다양화, 도메인 적응 기법
RT-DETR 활용 불가	232장으로 Transformer 학습 불충분	대규모 데이터 확보 후 재실험

8. 프로젝트를 통해 얻은 것

비개발자 출신으로 시작해 mAP@[0.75:0.95] 기반 객체 검출 프로젝트를 처음부터 끝까지 직접 수행했습니다. 단순히 코드를 실행하는 것을 넘어 왜 그 결과가 나왔는지를 분석하고 다음 실험을 설계하는 과정을 반복하면서 AI 엔지니어의 실무 사이클을 체득했습니다.

- 데이터 크기에 따른 모델 선택 기준 (Transformer vs CNN) — RT-DETR 실패가 오히려 명확한 인사이트 제공
- mAP@0.75 이상 고정밀 평가에서 해상도(`imgsz`)가 결정적 변수임을 체감
- 양상블은 '많을수록 좋다'가 아니라 '상호보완적 다양성'이 핵심
- `skip_box_thr` 파라미터 하나의 변경이 실제 점수에 영향을 주는 과정을 통해 하이퍼파라미터 감각 습득
- `category_id` 버그 → 근본 원인 파악 → 구조적 해결: 같은 실수를 반복하지 않는 디버깅 습관 형성
- Colab 학습 중 병렬 작업(외출·강의 수강) 패턴으로 시간 효율 극대화
- 딥러닝 개념(활성화 함수, CNN, GAN)이 실제 서비스(인생네컷·포토샵·틱톡 배경제거)와 연결되는 시각 확보

- KFA 서비스 파이프라인 설계 방향 구체화: MediaPipe(랜드마크) → CNN(얼굴형 분류) → 추천 모델

9. 부록: 프로젝트 디렉토리 구조

```
pill_detection/
├── data/
│   ├── train_images/ ← 232장
│   ├── train_annotations/ ← COCO JSON
│   └── test_images/ ← 842장
├── yolo_data/
│   ├── images/train|val/
│   ├── labels/train|val/
│   └── data.yaml
├── runs/ ← 모델별 학습 결과 (best.pt)
├── outputs/ ← 예측 CSV (pred_v8s.csv 등)
├── notebooks/
├── 01_EDA.ipynb
├── 02_preprocessing.ipynb
├── 03_train_yolo.ipynb
└── 04_ensemble_submit.ipynb
```